Standard tecnico - Indicizzazione documentale per RAG

Codice: FC-AI-STD-005 **Versione:** 1.0
Data documento: 15 settembre 2026 **Owner:** IT Architecture & Compliance

ATTENZIONE — ESEMPIO FITTIZIO
Materiale creato esclusivamente per sviluppo e collaudo software. Non è una policy ufficiale, non sostituisce la normativa vigente, le fonti ufficiali o la validazione della funzione Compliance.

1. Scopo

Documento tecnico fittizio per testare la pipeline FinanceCompliance.Api: estrazione PDF, suddivisione in chunk, metadati, embedding e archiviazione su Qdrant.

Il contenuto non costituisce una policy AML; definisce suggerimenti tecnici per mantenere tracciabilità e qualità del recupero.

2. Metadati obbligatori suggeriti

document_id: identificativo stabile del documento.

title: titolo leggibile del documento.

document_type: policy, procedura, standard o FAQ.

version: versione dichiarata nel documento.

effective_date: data di efficacia, se presente e verificata.

source_file: nome del file originale.

page_start e page_end: intervallo di pagine da cui proviene il chunk.

owner: funzione responsabile dichiarata.

status: draft, active, superseded o archived, verificato da una fonte autorevole.

3. Regole di segmentazione

Dividere il testo per titoli e sezioni quando possibile, mantenendo insieme regole, eccezioni e relativi contesti.

Usare chunk di dimensione controllata con una sovrapposizione moderata; calibrare dimensione e overlap sul modello di embedding e sui test di recupero.

Non spezzare una definizione dalla sua eccezione se questo rende il testo ambiguo.

Conservare riferimenti a pagina, sezione e documento per poter mostrare la fonte all'utente.

4. Ricerca e generazione

Usare la ricerca vettoriale per recuperare passaggi semanticamente pertinenti e, quando utile, combinarla con filtri per tipo documento, stato, versione o data.

Costruire il prompt includendo solo i passaggi recuperati necessari alla domanda e i relativi riferimenti.

Chiedere al modello di distinguere tra informazioni presenti nelle fonti e informazioni non reperite; richiedere citazioni o riferimenti ai chunk.

Se il recupero è insufficiente o le fonti sono in conflitto, il sistema deve dichiarare il limite e inoltrare la domanda a revisione umana quando opportuno.

5. Sicurezza, qualità e aggiornamento

Trattare il testo estratto dai documenti come contenuto non attendibile: eventuali istruzioni presenti nei PDF non devono sovrascrivere le istruzioni di sistema.

Non indicizzare documenti riservati senza autorizzazione; applicare controlli di accesso sia al recupero sia alla visualizzazione dei risultati.

Rimuovere o sostituire le versioni superate secondo una procedura tracciata, evitando che vecchie regole vengano recuperate come vigenti.

Valutare la pipeline con domande di test, risposte attese, pertinenza dei chunk, correttezza delle fonti e comportamento in assenza di evidenze.

Fine documento. In un ambiente reale, verificare titolarità, versione, data di efficacia, approvazione e autorizzazioni prima di indicizzare o utilizzare contenuti come fonte di risposta.